

맞습니다. AI가 결과물을 만들어냈다면, 그 결과물이 요구사항과 설계에 부합하고 안전하게 작동한다는 **입증 부담**은 AI 측에 우선 배치되어야 합니다. 다만 법적 책임 주체와 운영상 입증 주체는 구분해야 하며, 현재 자료는 AI 자체를 법적 책임자로 확정하기보다는 개발자·제공자·배포자 등 역할별 책임을 배분하는 방향을 제시합니다.

## 핵심 철학의 전환

기존 구조를 다음과 같이 수정하는 것이 적절합니다.

- **AI**: 자신이 생성하거나 수정한 결과물의 정확성, 요구사항 충족, 설계 준수, 테스트 통과, 보안 상태를 증거로 입증한다.
- **인간**: AI가 제출한 입증 자료를 바탕으로 승인, 거부, 재작업, 범위 축소, 롤백 여부를 결정한다.
- **개발 조직 또는 제공자**: AI가 충분한 증거를 생산하도록 검증 체계, 기록 체계, 테스트 환경을 제공한다.
- **최종 사용자**: 결과물의 품질을 대신 증명하는 사람이 아니라, 승인된 결과가 실제 목적에 적합한지 판단하는 의사결정권자로 참여한다.

AI 코딩 도구가 생성·수정·추천한 코드에 대한 정확성, 안전성, 법적 준수 책임이 사용자 측으로 이동하는 경향이 있다는 분석이 있으므로, 페어링 현상은 이 책임 전가를 방지하는 통제 장치를 별도로 선언해야 합니다. 또한 AI가 테스트를 통과했다라도 구현 목표를 조용히 바꾸거나 아키텍처 권한을 이동시킬 수 있다는 연구 결과가 있어, 단순한 테스트 성공만으로는 입증이 완성되지 않습니다.

## 개정 현장 핵심 조항

### 제1조: AI 입증 의무

1. AI는 자신이 생성, 수정, 제안한 모든 산출물에 대해 **\*\*입증책임자(Evidence Bearer)\*\***로 지정된다.
2. AI는 결과물의 품질을 주장하는 경우, 그 주장을 뒷받침하는 재현 가능한 근거를 함께 제출해야 한다.
3. 근거가 없거나 검증되지 않은 내용은 **UNVERIFIED** 로 표시한다.
4. AI는 인간의 침묵, 질문 생략, 형식적 확인을 승인으로 해석할 수 없다.
5. AI가 자신의 결과물을 입증하지 못한 경우 해당 작업은 **READY\_FOR\_ACCEPTANCE** 로 전환될 수 없다.

### 제2조: AI의 입증 범위

AI는 최소한 다음 사항을 직접 입증해야 한다.

- 요구사항 및 인수 조건 충족 여부
- 승인된 아키텍처와 ADR 준수 여부
- 계획된 파일만 변경했는지 여부
- 데이터 흐름과 인터페이스의 일관성
- 정상·오류·경계·권한·복구 시나리오의 동작
- 단위·통합·회귀 테스트 결과
- 린트·타입 검사·빌드 결과
- 보안 취약점과 개인정보 처리 영향
- 미검증 영역, 알려진 제한사항, 잔여 위험
- 실행 환경, 버전, 명령어, 실행 시각, 로그 위치

AI가 생산한 코드의 수용을 검토 없이 진행할 경우 보안 결함과 논리 오류가 증가할 수 있다는 연구 결과가 있으므로, 입증 자료에는 코드 결과뿐 아니라 검증 과정 자체의 기록도 포함해야 합니다.

# 제3조: AI 입증 보고서의 증거 기준

AI의 보고는 다음 세 등급으로 구분합니다.

| 등급               | 의미                      | 인간에게 제공되는 상태  |
|------------------|-------------------------|---------------|
| PROVEN           | 실행 결과와 재현 가능한 자료가 확인됨   | 승인 심사 가능      |
| PARTIALLY_PROVEN | 일부 항목만 입증되었거나 제한사항이 존재함 | 조건부 검토 또는 재작업 |
| UNPROVEN         | 실행하지 않았거나 근거가 부족함       | 승인 심사 금지      |

PROVEN 은 “문제가 없음”이라는 뜻이 아니라, 보고된 주장에 대응하는 시험과 자료가 존재한다는 뜻으로 정의해야 합니다. AI 주도 입증은 인간의 판단을 제거하는 방식이 아니라, 인간이 판단할 수 있도록 증거를 먼저 구조화하는 방식이어야 합니다.

## 개정된 페이지 구조

### PHASE 0: Context

AI는 코드베이스, 의존성, 실행 환경, 기존 규칙을 조사하고 조사 범위와 미확인 사항을 보고합니다.

### PHASE 1: Problem

AI는 문제의 원인과 영향 범위를 분석하고, 분석에 사용한 파일·로그·요구사항을 제시합니다.

### PHASE 2: Requirements

AI는 요구사항과 인수 조건을 작성하며, 각 조건에 대응하는 검증 방법을 함께 제시합니다.

### PHASE 3: Architecture

AI는 두 개 이상의 대안을 비교하고, 선택된 대안이 요구사항을 만족한다는 논거와 예상 위험을 제출합니다.

### PHASE 4: System Design

AI는 컴포넌트, 인터페이스, 데이터 흐름, 오류 처리, 보안 경계를 설계하고 설계 간 모순이 없음을 확인합니다.

### PHASE 5: Implementation Plan

AI는 수정 파일, 구현 순서, 테스트 방법, 롤백 절차, 입증 산출물을 명시합니다.

### PHASE 6: Implementation

AI는 승인된 계획 안에서 구현하고, 변경된 모든 내용을 추적 가능한 형태로 기록합니다.

### PHASE 7-A: AI Proof

AI는 구현 결과를 직접 실행·검사하고 다음 자료를 제출합니다.

- 변경 파일 목록과 변경 이유
- 요구사항별 입증 매트릭스
- 테스트 명령과 원문 결과
- 실패 및 재실행 기록
- 커버리지와 품질 지표
- 보안·권한·개인정보 점검 결과
- 아키텍처 및 ADR 비교 결과
- 재현 절차와 로그 위치
- 미입증 항목과 잔여 위험

## PHASE 7-B: Human Decision

인간은 AI가 제출한 입증 자료를 근거로 다음 중 하나를 결정합니다.

- **FINAL\_ACCEPTED**
- **CONDITIONALLY\_ACCEPTED**
- **REJECTED**
- **REWORK\_REQUIRED**
- **ROLLBACK\_REQUIRED**

인간의 역할은 시험을 대신 수행하는 검사자가 아니라, 입증 자료의 충분성, 위험 수용 여부, 사용자 목적과의 적합성을 판단하는 최종 결정자입니다. AI의 실질적 기여가 작거나 인간이 AI의 능력을 과소·과대평가하는 경우 책임 판단이 왜곡될 수 있다는 연구도 있으므로, 승인 화면에는 AI와 인간의 기여 범위 및 확신 수준을 함께 표시해야 합니다.

### CURRENT\_STATE.md 개정안

#### ## 1. 현재 작업 정보

- `FEATURE_NAME`: ``
- `CURRENT_PHASE`: `PHASE 0 (CONTEXT)`
- `TASK_STATUS`: `IN\_PROGRESS`
- `PROOF_STATUS`: `UNPROVEN`
- `PROOF_OWNER`: `AI\_AGENT`
- `DECISION_OWNER`: `HUMAN\_LEAD`

#### ## 2. 입증 상태

- `REQUIREMENTS_PROOF`: `UNPROVEN`
- `ARCHITECTURE_PROOF`: `UNPROVEN`
- `DESIGN_PROOF`: `UNPROVEN`
- `IMPLEMENTATION_PROOF`: `UNPROVEN`
- `TEST_PROOF`: `UNPROVEN`
- `SECURITY_PROOF`: `UNPROVEN`

```
- USER_IMPACT_PROOF: `UNPROVEN`
```

### ## 3. 입증 자료

```
- Verification Report: `specs/verification_report.md`  
- Test Logs: ``  
- Change Manifest: ``  
- Build Artifact: ``  
- Commit: ``  
- Reproduction Command: ``
```

### ## 4. 결정 상태

```
- HUMAN_DECISION: `PENDING`  
- DECISION_REASON: `-`  
- DECISION_TIMESTAMP: `--`  
- DECISION_SIGN_OFF: `--`
```

상태 변경 권한은 분리해야 합니다. AI는 **PROVEN**, **PARTIALLY\_PROVEN**, **UNPROVEN** 과 같은 입증 상태를 갱신할 수 있지만, **FINAL\_ACCEPTED**, **COMPLETED**, **REJECTED** 는 인간의 명시적 결정으로만 변경되도록 해야 합니다. AI를 RACI의 **Responsible** 또는 **Support** 로 배치할 수는 있지만 **Accountable** 로 지정할 수 없다는 책임 모델도 이러한 구분을 전제로 합니다.

## VERIFICATION\_REPORT.md 개정안

### # AI Proof Report

```
- Feature: ``  
- Proof Owner: `AI Agent`  
- Decision Owner: `Human Lead`  
- Proof Status: `PROVEN | PARTIALLY_PROVEN | UNPROVEN`  
- Generated At: ``  
- Source Commit: ``  
- Environment: ``
```

### ## 1. Proof Claims

| Claim ID | AI 주장 | 근거               | 실행 결과 | 상태                 |
|----------|-------|------------------|-------|--------------------|
| P-001    | ``    | `[테스트/로그/코드 위치]` | ``    | `PROVEN`           |
| P-002    | ``    | `[ADR/검사 결과]`    | ``    | `PROVEN`           |
| P-003    | ``    | `[스캔/검사 결과]`     | ``    | `PARTIALLY_PROVEN` |

## ## 2. Requirement-to-Proof Matrix

| 요구사항 | 검증 방법 | 실행 명령 | 결과          | 미충족 사항 |
|------|-------|-------|-------------|--------|
| ---  | ---   | ---   | ---         | ---    |
| ``   | ``    | ``    | `PASS/FAIL` | ``     |

## ## 3. Executed Evidence

- Unit Tests:
- Integration Tests:
- Regression Tests:
- Lint:
- Type Check:
- Build:
- Security Scan:
- Accessibility Check:
- Manual Reproduction Provided by AI:

## ## 4. Scope Conformance

- Planned Files:
- Actual Changed Files:
- Unauthorized Changes:
- Generated Diff Summary:

## ## 5. Known Gaps

- Not Executed:
- Not Reproducible:
- Insufficient Evidence:
- Residual Risks:

## ## 6. AI Declaration

본 보고서에서 `PROVEN`으로 표시한 항목은 기록된 명령과 자료로 재현할 수 있습니다.  
실행하지 않은 검사는 통과로 표시하지 않았습니다.  
확인하지 못한 내용은 `UNPROVEN`으로 표시했습니다.

## ## 7. Human Decision

- [ ] FINAL\_ACCEPTED
- [ ] CONDITIONALLY\_ACCEPTED
- [ ] REJECTED
- [ ] REWORK\_REQUIRED
- [ ] ROLLBACK\_REQUIRED

Decision Reason:

Sign-off:

Date:

## STOP-THE-LINE 개정안

### AI 입증 실패 또는 충돌

1. 입증하지 못한 주장:
2. 관련 요구사항 또는 ADR:
3. 발생 위치:
4. 실행한 검사:
5. 검사 원문 결과:
6. 증거가 부족한 이유:
7. 사용자 및 시스템 영향:
8. 보안·개인정보·규제 영향:
9. 현재 상태:
10. 가능한 대안:
11. AI 권장안:
12. 작업 재개에 필요한 추가 증거:
13. 인간 결정 필요 사항:
14. 승인 또는 재개 기록:

## 최종 개정 원칙

이 현장은 다음 한 문장으로 정리할 수 있습니다.

따라서 **Human-in-the-Loop** 라는 표현도 단순한 인간 확인 절차가 아니라, **AI가 입증 자료를 생산하고 인간이 권한 있는 결정을 내리는 증거 기반 협업 구조**로 재정의하는 것이 좋습니다. 인간의 감독이 의미 있으려면 실제로 개입할 수 있는 권한과 충분한 정보가 있어야 하며, AI가 사람을 형식적인 승인자로 만들면 실질적인 통제가 약화될 수 있습니다. AI 주도 입증과 인간 주도 결정의 결합은 AI의 작업 결과에 대한 증거 생산 의무를 분명히 하면서도, 승인 여부와 위험 수용에 관한 최종 판단 권한을 인간에게 남기는 구조입니다.

## 참고 자료

1. [Intelligence brings responsibility - Even smart AI assistants are held responsible](#)
2. [Judging One's Own or Another Person's Responsibility in Interactions With Automation](#)
3. [Theoretical, Measured, and Subjective Responsibility in Aided Decision Making](#)
4. [Who Is Responsible When Human-AI Collaboration Fails? The Role of Perfect Automation Beliefs and Self-Assessed Expertise in Responsibility Attribution](#)

5. [Toward Safe and Responsible AI Agents: A Three-Pillar Model for Transparency, Accountability, and Trustworthiness](#)
6. [Ethics, Authorship, and Transparency](#)
7. [Builder, Defender, Breaker: The Case Against Removing the Human from the AI-Driven Security Lifecycle](#)
8. [The Accountability Paradox: How Generative AI Challenges Our Notions of Responsibility](#)
9. [Why Human-AI "Collaboration" Is a Category Error](#)
10. [AI-Induced Human Responsibility \(AIHR\) in AI-Human teams](#)
11. [Accountable Agents in Software Engineering: An Analysis of Terms of Service and a Research Roadmap](#)
12. [Human-in-the-Loop Governance for LLM-Generated Code: An Engineering Control, Accountability, and Verification Model in AI-Augmented Software Development](#)
13. [Using AI in HR decision-making: what HR leaders must change to avoid bias, blind automation and loss of trust?](#)
14. [HAiMR™ — Human-Accountable AI Responsibility Model](#)
15. [Generative AI and Humans](#)
16. [Redefining Work in Automation-Driven Fields: The Role of Human-AI Collaborative Systems](#)
17. [Arbitration-Driven Development: A Governance Framework for Trustworthy AI-Assisted Software Engineering](#)
18. [Human-AI Collaboration in Defense Intelligence](#)
19. [Navigating Generative AI Disclosure, Ownership, and Accountability in Co-Creative Domains](#)
20. [AI Charter — Human Responsibility Boundaries in Human-AI Collaboration \(Bánkuti Omri\)](#)
21. [Regulatory Human-Agent Teams: Co-Creating Ethical Oversight](#)
22. [Human Feasibility Constrained AI: A Conceptual Framework for Next-Generation Human-AI Systems](#)
23. [Ethical and Legal Challenges of Partially and Fully Autonomous AI in Healthcare: Reinterpreting Liability and Preserving Trust.](#)
24. [Objective and Subjective Responsibility of a Control-Room Worker](#)
25. [Who is responsible for self-AI or others-AI collaboration? The effect of power and task outcome in responsibility attribution.](#)
26. [Insights From Human-Ai Collaboration](#)
27. [When LLMs Pass Tests but Fail the Process: A Governance Framework and Empirical Study of Multi-Agent LLM Software Development](#)
28. [Designing Human-AI Collaboration Models for Commercial Decision Systems: A Business Management Perspective](#)
29. [Humans are Missing from AI Coding Agent Research](#)
30. [Human-In-The-Loop Large Language Models for Decision Support in Modern Power Systems: Capabilities, Risks, and Governance](#)
31. [AI기본법상 AI사업자 의무와 형사법상 조직책임](#)
32. [EU법제상 AI제조물에 대한 책임과 안전\\*](#)

33. [AI Risk Management Framework](#)
34. [Article 26: Obligations of Deployers of High-Risk AI Systems](#)
35. [Accountability \(OECD AI Principle\)](#)
36. [AI 자율주행자동차 사고 책임과 형사제재](#)
37. [\[PDF\] 생성형 AI 서비스제공자의 법적 책임과 입법적 시사점](#)
38. [NIST AI RMF 1.0 Implementation Guide for Enterprises 2026](#)
39. [AI Act | Shaping Europe's digital future](#)
40. [AI principles](#)
41. [Understanding the NIST AI RMF: What It Is and How to Put ...](#)
42. [EU AI Act Conformity Assessment: What Providers Must Do ...](#)
43. [OECD AI Principles overview](#)
44. [인공지능 오류로 사고 났을 때 누구 책임? 법적 문제 정리돼야 시장이 ...](#)
45. [NIST AI Risk Management Framework \(AI RMF 1.0\)](#)
46. [Eu Ai Act 2026 Compliance Clock](#)
47. [Recommendation of the Council on Artificial Intelligence](#)
48. [AI로봇의 형사법적 지위 - 법학연구 - 한국법학회 - KISS](#)
49. [AI 시대 기업이 꼭 알아야 할 법률 | 인사이트리포트 | 삼성SDS](#)
50. [Artificial Intelligence Risk Management Framework](#)
51. [High-Risk AI Systems Under the EU AI Act: Deployer Guide](#)
52. [OECD AI Principles](#)
53. [인공지능 규제법, 책임법, 그리고 보험](#)
54. [\[PDF\] 본 보고서를 인공지능서비스 이용자 보호를 위한 법제 도입](#)
55. [NIST AI Risk Management Framework](#)
56. [Article 50: Transparency Obligations for Providers and ...](#)
57. [OECD Updates Guidance on Responsible AI](#)
58. [생성형 AI와 인간 행위자간 형사책임의 구성 방안](#)
59. [생성형 AI에 대한 인간의 감독이 중요합니다: 따라야 할 10가지 지침](#)
60. [NIST AI RMF](#)
61. [EU AI Act Compliance Checklist 2026](#)
62. [OECD AI Principles: The 5 Values, 2019 & 2024](#)
63. [AI 개발에서 인간의 감독 역할: 윤리적 원칙과 책임 있는 혁신 - Nemko](#)
64. [NIST's AI Risk Management Framework: What It Is, Why It ...](#)
65. [Section 3: Obligations of Providers and Deployers of High- ...](#)
66. [OECD Due Diligence Guidance for Responsible AI](#)
67. [\[Tech Legal Insights\] AI 모빌리티, 혁신이냐 책임이냐](#)
68. [\[PDF\] 제조물책임 범위의 확장 : SW와 AI의 적용가능성](#)
69. [NIST AI RMF Principle: Govern](#)
70. [What assessments are required under the EU's AI Act?](#)
71. [인공지능 알고리즘을 활용한 전문\(추천\) 서비스 제공의 법적 ...](#)
72. [\[PDF\] 생성형 인공지능과 저작권 및 창작자 보호 문제](#)
73. [인공지능\(AI\) 산출물에 대한 각국 법원의 판결 - 네플라](#)
74. [Responsible use of GitHub Copilot features](#)
75. [Responsible AI: Ethical policies and practices](#)
76. [GitHub Copilot · Your AI pair programmer](#)



77. [Microsoft Enterprise AI Services Code of Conduct](#)
78. [GitHub Copilot Review 2026: AI Developer Assistant Insights](#)
79. [Responsible AI Principles and Approach](#)
80. [인공지능 로봇의 형사책임 —논의방향의 설정에 관한 몇 ... - KISS](#)
81. [AI 의사 결정에 대한 법적 책임: 알고리즘이 실패할 때 누가 ...](#)
82. [Application card: GitHub Copilot Agents](#)
83. [Responsible AI: Why it matters and how we're infusing it ...](#)
84. [Responsible AI with GitHub Copilot - Training](#)
85. [Responsible AI Framework Microsoft Enterprise 2026](#)
86. [인공지능 로봇에 관한 형사책임 - 인공지능형법에 의한 형사 ...](#)
87. [GitHub Copilot Review: Honest Verdict 2026](#)
88. [Transparency Report - Microsoft](#)
89. [Responsible AI Practices and Ethical Use of GitHub Copilot](#)
90. [Microsoft's new responsible tech lead on high-speed AI ...](#)
91. [Updates to our Privacy Statement and Terms of Service](#)
92. [Microsoft Responsible AI Standard \(International, 2026\)](#)
93. [인공지능\(AI\)의 입법적 쟁점에 관한 고찰](#)
94. [Security and responsible AI for Windows development](#)
95. [인공지능과 법적 쟁점 - - AI가 만들어낸 결과물의 법률 문제 ...](#)

