

제시된 문서를 **HUMAN-IN-THE-LOOP(HITL)** 및 사용자 중심 개발 원칙 관점에서 검토하면, 핵심 방향은 매우 적절합니다. 특히 인간을 최종 의사결정자와 인수자로 지정하고, AI의 역할을 제안·분석·구현 보조로 제한한 점은 HITL의 취지와 일치합니다. HITL은 자동화 과정에 인간이 참여해 정확성, 안전성, 책임성, 윤리적 판단을 보장하는 접근입니다. 다만 현재 문서는 “인간 승인”을 강하게 규정한 반면, 승인 절차의 실행 가능성, 사용자 검증, 책임 추적, 긴급 중단, 보안 통제를 더 구체화할 필요가 있습니다.

✓ 총평

현재 문장은 다음 네 가지 측면에서 강점이 있습니다.

- **인간의 최종 권한 명시:** AI가 **COMPLETED** 를 선언하지 못하고 **READY_FOR_ACCEPTANCE** 까지만 보고하도록 한 점은 권한 경계를 명확히 합니다.
- **단계별 승인 게이트:** 문제 정의부터 구현, 검증, 인수까지 승인을 분리해 AI가 기술적 판단을 사업적 승인으로 오인하지 않도록 했습니다.
- **상태 기반 통제:** **CURRENT_STATE.md** 를 기준으로 구현 권한을 통제하는 방식은 대화 내용이나 임의 지시로 절차가 우회되는 것을 막는 데 유용합니다.
- **중단 권한:** 모호성이나 아키텍처 충돌이 발견되면 구현을 멈추도록 한 **STOP-THE-LINE** 은 안전 중심 운영에 적합합니다.

AI 개발 도구의 공식 운영 지침도 AI 결과물을 인간 검토의 대체물이 아니라 보조 수단으로 사용해야 하며, 생성된 코드와 명령을 검토하고 테스트할 책임이 사용자에게 있다고 설명합니다. 따라서 문서의 철학 자체는 현재의 책임 있는 AI 개발 원칙과 잘 맞습니다.

⚠ 핵심적으로 보완할 부분

1. “인간 승인”을 형식적 서명 이상으로 정의해야 합니다

현재 문서는 인간의 승인 권한을 명확히 했지만, 무엇을 확인해야 승인할 수 있는지는 충분히 구체적이지 않습니다. HITL에서 인간은 단순히 승인 버튼을 누르는 존재가 아니라 AI 결과를 검증하고, 필요하면 수정·차단·재작업을 요구할 수 있어야 합니다.

다음 항목을 **Human Acceptance** 의 필수 조건으로 추가하는 것이 좋습니다.

- 요구사항과 실제 구현의 일치 여부
- 주요 사용자 시나리오의 성공 여부
- 오류·예외·권한 부족 상황의 동작
- 보안 및 개인정보 영향
- 성능과 운영 가능성
- 변경된 파일과 데이터 흐름에 대한 이해
- 테스트 결과와 테스트 자체의 적절성
- 알려진 제한사항과 잔여 위험에 대한 수용 여부

즉, ``는 단순한 서명이 아니라 “무엇을 검토했고 어떤 위험을 수용했는지”를 남기는 결정 기록이어야 합니다.

2. INCOMPLETE 상태가 상태 목록에 없습니다

현장 제6조에서는 인간 승인 전 작업을 **INCOMPLETE** 로 남긴다고 규정했지만, **CURRENT_STATE.md** 의 허용 상태 목록에는 **INCOMPLETE** 가 없습니다. 현재 목록은 **NOT_STARTED** , **IN_PROGRESS** , **BLOCKED** , **READY_FOR_ACCEPTANCE** , **COMPLETED** 로만 구성되어 있어 문서 간 불일치가 발생합니다.

다음 중 하나로 통일해야 합니다.

- 상태 목록에 **INCOMPLETE** 를 추가
- 승인 전 상태를 **READY_FOR_ACCEPTANCE** 또는 **IN_PROGRESS** 로 통일
- **INCOMPLETE** 를 최종 상태가 아닌 설명용 표현으로 변경

권장 방식은 다음과 같습니다.

```
TASK_STATUS:
NOT_STARTED
IN_PROGRESS
BLOCKED
READY_FOR_ACCEPTANCE
ACCEPTANCE_REJECTED
COMPLETED
```

인간이 거부한 작업을 단순히 **IN_PROGRESS** 로 되돌리기보다 **ACCEPTANCE_REJECTED** 로 기록하면 거부 사유와 재작업 흐름을 추적하기 쉽습니다.

3. AI가 **CURRENT_STATE.md**를 직접 변경할 수 있는지 명시해야 합니다

CURRENT_STATE.md 를 SSOT로 지정했지만, 누가 이 파일을 수정할 수 있는지는 분명하지 않습니다. AI가 상태 문서를 직접 수정할 수 있다면, 구현 권한이나 완료 상태를 잘못 변경하는 위험이 생깁니다.

다음과 같이 권한을 분리하는 것이 안전합니다.

- AI: 관찰 결과, 검증 결과, 제안 상태를 보고
 - 인간: 승인 상태, 구현 권한, 최종 상태, 페이즈 전환을 기록
 - 자동화 도구: 테스트 결과와 커밋 식별자 등 기계적으로 검증 가능한 정보만 기록
 - AI: 인간 승인 없이 **COMPLETED** , **APPROVED** , **FINAL ACCEPTED** 를 기록하지 않음
- 특히 상태 변경에는 다음 정보를 함께 남기는 것이 좋습니다.

- 변경 전 상태
- 변경 후 상태
- 변경 사유
- 변경자
- 변경 시각

- 관련 커밋 또는 산출물 식별자

4. "최종 검증"이 개발자 한 명에게 과도하게 집중될 수 있습니다

인간 주도권은 반드시 한 명의 개발자가 모든 검증을 혼자 수행한다는 뜻은 아닙니다. 고위험 영역에서는 적절한 역량을 가진 사람이 시스템의 한계와 위험을 이해하고 개입 권한을 가져야 한다는 점이 중요합니다. 따라서 역할을 다음처럼 구분하는 편이 더 현실적입니다.

- **Human Lead:** 범위, 우선순위, 아키텍처 및 최종 승인
- **Domain Reviewer:** 업무 규칙과 사용자 시나리오 검토
- **Security Reviewer:** 보안, 권한, 개인정보 검토
- **QA 또는 Test Reviewer:** 테스트 전략과 결과 검토
- **AI Agent:** 분석, 구현, 자동 검증, 위험 보고

최종 승인권은 Human Lead가 보유하되, 특정 위험 영역에는 전문 검토를 필수화하는 구조가 적절합니다.

5. 사용자 중심성이 아직 선언 수준에 머물러 있습니다

현재 문서는 개발자와 AI 사이의 통제 절차는 잘 정의하지만, 실제 사용자의 관점과 권리가 어떻게 반영되는지는 상대적으로 약합니다. 사용자 중심 개발을 강조하려면 요구사항과 인수 조건에 다음을 포함해야 합니다.

- 실제 사용자 문제와 기대 결과
- 사용자 여정 또는 대표 시나리오
- 접근성 요구사항
- 오류 발생 시 사용자가 이해할 수 있는 안내
- 사용자가 결과를 수정하거나 이의를 제기할 수 있는 방법
- 자동화 결과로 영향을 받는 사용자의 보호 장치

AI 시스템은 모호성, 편향, 예외 상황에서 오류를 낼 수 있으므로 인간 피드백은 정확성과 안전성을 높이는 보호 장치가 될 수 있습니다. 따라서 인간 승인뿐 아니라 최종 사용자의 피드백과 사용성 검증도 별도 게이트로 다루는 것이 좋습니다.

STOP-THE-LINE 프로토콜 보완안

현재 템플릿은 충돌 보고에는 적합하지만, 실제 운영에 필요한 즉시 통제 항목이 부족합니다. 다음 항목을 추가하면 더 강력해집니다.

충돌 및 의사결정 요청

1. 충돌 또는 이상 징후:
2. 발견 시점:
3. 관련 파일, 기능, 커밋:
4. 사용자 영향:
5. 보안·개인정보·규제 영향:

6. 현재 작업 상태:
7. 즉시 취한 격리 또는 롤백 조치:
8. 선택 가능한 대안:
 - Option A:
 - Option B:
9. AI 권장안:
10. 인간이 결정해야 할 사항:
11. 재개 조건:
12. 재개 승인자:

AI 에이전트가 파일을 수정하거나 명령을 실행하는 환경에서는 권한 요청과 변경 범위를 사람이 검토해야 하며, 위험한 명령은 실행 전에 확인해야 합니다. 따라서 중단 프로토콜에는 코드뿐 아니라 명령 실행, 외부 도구, MCP 연동, 데이터 접근도 포함해야 합니다.

VERIFICATION_REPORT.md의 문제점

현재 검증 보고서는 실제 결과 보고서와 예시가 섞여 있습니다. 예를 들어 **12/12 Passed**, **Coverage: 94%**, **ADR-0002 준수** 와 같은 값은 실제 실행 결과가 아니라 템플릿에 고정된 예시처럼 보입니다. 이 상태로 사용하면 실행하지 않은 검증을 완료한 것처럼 오해할 수 있습니다.

다음처럼 모든 결과를 변수 또는 빈칸으로 바꾸는 것이 안전합니다.

2. 자동화 테스트 결과

```
- **실행 명령**: ``
- **실행 시각**: ``
- **Unit Tests**: ` `/`
- **Integration Tests**: ` `/`
- **Coverage**: ``
- **Lint**: ``
- **Type Check**: ``
- **실패 테스트**: ``
```

또한 **READY_FOR_HUMAN_ACCEPTANCE** 는 검증 성공을 의미하는 상태가 아니라, AI가 검증 자료를 제출하고 인간 검토를 요청하는 상태로 정의해야 합니다. AI 생성 코드는 문법적으로 맞아 보여도 의미상 오류나 보안 취약점을 포함할 수 있으므로, 자동 테스트 통과만으로 충분하지 않습니다.

현재 페이지 구조에 대한 평가

페이지 구조는 통제력이 강하고 책임 경계를 분명히 한다는 장점이 있습니다. 특히 구현 전에 요구사항, 아키텍처, 설계, 계획을 승인하도록 한 점은 AI가 먼저 코드를 작성한 뒤 사후적으로 정당화하는 흐름을 막습니다.

다만 모든 작업에 동일한 8단계를 강제하면 작은 수정이나 긴급 장애 대응에서 과도한 절차가 될 수 있습니다. 다음과 같이 작업 유형별 경로를 구분하는 방식이 더 실용적입니다.

작업 유형	권장 절차
신규 기능	전체 페이지 수행
보안·권한·개인정보 변경	전체 페이지와 전문 검토 필수
단순 버그 수정	문제 정의, 영향 분석, 구현 계획, 구현, 검증, 인간 승인
문서·주석 수정	범위 확인, 변경, 검토
긴급 장애 대응	즉시 완화, 인간 승인, 사후 분석과 문서화

단, 축약 경로를 사용하더라도 인간 승인과 변경 기록은 생략하지 않는 것이 핵심입니다. AI 위험 관리는 설계, 개발, 사용, 평가 전 과정에서 신뢰성 요소를 반영하는 것을 목표로 하며, NIST AI RMF는 이러한 위험 관리를 위한 자발적 프레임워크로 제시되어 있습니다.

문서에 추가하면 좋은 핵심 조항

다음 조항을 현장에 직접 추가하면 현재의 철학이 더 명확하고 실행 가능해집니다.

인간 주도권 조항

제7조 (인간 주도권과 실질적 개입권)

1. 인간은 AI의 제안, 분석, 코드, 테스트 결과를 승인하거나 거부할 수 있다.
2. 인간의 승인은 AI 결과를 자동으로 신뢰한다는 의미가 아니라, 요구사항·사용자 영향·위험·검증 결과를 검토했다는 의미이다.
3. 인간은 언제든지 작업을 일시 중지, 범위 축소, 재설계, 롤백 또는 폐기할 수 있다.
4. AI는 인간의 승인 신호를 추정하거나 암묵적 동의로 간주할 수 없다.
5. 인간의 응답이 없거나 승인 여부가 불명확한 경우 작업 상태는 승인 대기로 유지한다.

사용자 영향 조항

제8조 (사용자 중심성과 영향 검토)

1. 모든 기능은 구현 전에 대상 사용자, 사용자 문제, 기대 효과, 실패 시 영향을 기록해야 한다.

2. 인수 조건에는 정상 흐름뿐 아니라 오류, 오용, 접근성, 권한, 개인정보 및 복구 시나리오를 포함해야 한다.
3. 사용자에게 중대한 영향을 미치는 기능은 인간의 수동 검토와 명확한 이의 제기 또는 수정 경로를 제공해야 한다.
4. 사용자 피드백과 운영 중 발견된 피해 사례는 다음 작업의 요구사항과 위험 기록에 반영해야 한다.

AI 한계 및 불확실성 조항

제9조 (불확실성 및 증거의무)

1. AI는 확인하지 않은 내용을 사실로 보고할 수 없다.
2. AI는 테스트를 실행하지 않았으면 테스트 통과를 보고할 수 없다.
3. AI는 검토하지 않은 파일을 검토했다고 보고할 수 없다.
4. AI는 불확실성, 미검증 영역, 제한사항, 잔여 위험을 보고서에 명시해야 한다.
5. 검증 결과에는 실행 명령, 실행 시각, 대상 버전, 실패 내역 및 로그 위치를 포함해야 한다.

최종 판단

이 문서는 **인간이 최종 판단권과 인수권을 보유하는 AI 협업 개발 현장**으로서 기본 방향이 좋습니다. 특히 AI를 자율적인 최종 결정자가 아니라 분석가, 구현자, 검증 보조자로 제한한 점은 HITL의 핵심인 인간의 감독·개입·책임 원칙과 부합합니다.

다만 현재 상태로는 철학과 권한 선언이 강한 반면, 다음 운영 세부사항이 부족합니다.

- 승인자의 실제 검토 의무
- 상태 변경 권한과 감사 기록
- **INCOMPLETE** 상태 불일치
- 예시 검증 수치의 오해 가능성
- 사용자 영향 및 사용성 검증
- 보안·개인정보·외부 도구에 대한 별도 통제
- 작업 규모별 예외 절차
- 승인 거부와 재작업 흐름

따라서 이 문서는 폐기할 수준이 아니라, **원칙 현장으로는 합격이지만 운영 프로토콜로 사용하려면 보완이 필요한 초안**으로 평가하는 것이 정확합니다. 가장 먼저 **FINAL ACCEPTANCE**의 필수 검토 항목, 상태 전이 규칙, AI의 상태 파일 수정 권한, 검증 보고서의 실제 증거 형식을 확정하는 것이 좋습니다.

참고 자료

1. [AI Risk Management Framework](#)
2. [What Is Human In The Loop \(HITL\)?](#)
3. [Application card: GitHub Copilot Agents](#)
4. [Exploring Human-in-the-Loop Themes in AI Application ...](#)
5. [A 2026 Guide to Human-in-the-Loop](#)
6. [Human in the Loop AI Governance: A Practical Guide](#)
7. [Learned about Responsible AI with GitHub Copilot](#)
8. [Human-AI Collaboration in Software Engineering](#)
9. [NIST AI Risk Management Framework \(RMF\)](#)
10. [Responsible AI with GitHub Copilot - Training](#)
11. [Human Oversight in AI Software Development | Rob Klopp ...](#)
12. [Future of Human-in-the-Loop AI \(2026\) - Emerging Trends ...](#)
13. [NIST AI RMF 1.0 Implementation Guide for Enterprises 2026](#)
14. [GitHub Copilot Review 2026: AI Developer Assistant Insights](#)
15. [The practical 'human in the loop' framework](#)
16. [6 AI-Human Development Collaboration Models That Work](#)
17. [Human in the loop artificial intelligence in healthcare](#)
18. [AI Risk Management Framework \(AI RMF 2026\)](#)
19. [GitHub Copilot · Your AI pair programmer](#)
20. [Human-in-the-Loop for AI: A Collaborative Future ...](#)
21. [From Human-in-the-Loop to AI-governing-AI](#)
22. [NIST AI Risk Management Framework \(AI RMF 1.0\)](#)
23. [What is the Responsibility of Developers Using Generative AI ...](#)
24. [Ensuring Human Oversight in High-Performance AI Systems](#)
25. [From Human-in-the-Loop to AI-on-the-Loop: Redesigning ...](#)
26. [NIST AI RMF Human Oversight Controls: A Practical Guide](#)
27. [The Human-in-the-Loop Is an AI Governance Design ...](#)
28. [AI Decision-Making and Human Oversight in AI SDLC](#)
29. [Human in the Loop: Definition, Stakes and AI Oversight](#)
30. [AI Governance and the NIST AI Risk Management ...](#)
31. [Microsofts Six Principles of Responsible AI](#)
32. [Human in the Loop AI Governance Framework](#)
33. [What's your approach to human-AI collaboration in ...](#)
34. [Global AI Governance Overview: Understanding ...](#)
35. [To Copilot and Beyond:22 AI Systems Developers Want Built](#)
36. [Human-in-the-Loop AI for Finance: Governance and Control ...](#)
37. [EU AI Act vs NIST AI RMF vs ISO/IEC 42001](#)
38. [39.Human-AI Collaboration in Software Engineering-Best ...](#)
39. [Human-in-the-Loop Artificial Intelligence: A Systematic ...](#)

